



SVEUČILIŠTE U ZAGREBU · FAKULTET ELEKTROTEHNIKE I RAČUNARSTVA

DIPLOMSKI RAD

Primjena federiranog učenja za predviđanje opterećenja u mrežama električnih punionica

STUDENT

Zvonimir Žunić

MENTOR


prof. dr. sc. Gordan Ježić

Zagreb, 2. srpnja 2026.

Uvod i problem



Operateri trebaju procjenu opterećenja punionica za sljedeći sat; podaci su raspršeni po stanicama i osjetljivi, pa je centralizacija često neizvediva.




1 Koliko su jake naivne reference?

2 Koliko ih LSTM i rezidualni LSTM nadmašuju?

3 Kako se FedAvg i FedProx ponašaju u IID i non-IID raspodjeli?

- **UrbanEV** (Shenzhen, javne punionice; otvoreni skup)
- cilj: **volume** (kWh napunjeno po satu)
- **40** stanica
- input: **20** značajki kroz **24** sata
- uzorci: **174 959** ukupno
- kronološka podjela 70 / 5 / 25, StandardScaler



Prosječni dnevni profil: izražena dnevna sezonalnost (radni dan $\approx$ vikend)

Pristupi koje uspoređujemo


| **Naivni modeli:** zadnja vrijednost i sezonski 24 h; donja referenca bez učenja

| **Standardni LSTM (centralizirani):** glavni model treniran nad objedinjenim podacima svih stanica

| **Rezidualni LSTM:** uči korekciju na sezonsku prognozu od 24 h; ugrađeno domensko znanje, najbolji model

| **Federirano (FedAvg, FedProx):** učenje preko više stanica bez dijeljenja sirovih podataka

LSTM ćelija




Zaboravna, ulazna i izlazna vrata kontroliraju tok informacija kroz vrijeme; gating rješava nestajuće gradijente, a eksplodirajuće gasi gradient clipping

Federirano učenje



Lokalno treniranje, razmjena samo parametara, agregacija, globalni model natrag (kroz runde)



FedAvg: ponderirani prosjek parametara

$$w_{t+1} = \sum_{k=1}^K \frac{n_k}{n} w_{t+1}^{(k)}$$

FedProx: proksimalni član drži lokalni blizu globalnog

$$\min_w F_k(w) + \frac{\mu}{2} \|w - w_t\|^2$$

Rezultati



RMSE

$$\sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

kažnjava velike greške · kWh

MAE

$$\frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

prosječna apsolutna greška · kWh

R²

$$1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$$

udio objašnjene varijance

PRISTUP	SCENARIJ	RMSE [KWH]	MAE [KWH]	R ²	× VS NAJBOLJI
Naivni: zadnja vrijednost	centralizirano	337.21	85.32	0.878	1.51×
Naivni: sezonski 24 h	centralizirano	275.57	95.60	0.919	1.23×
Standardni LSTM	centralizirano	275.81	86.24	0.923	1.23×
Rezidualni LSTM	centralizirano	223.56	79.76	0.947	1.00×
FedProx	federirano · IID	652.06	177.24	0.567	2.92×
FedProx	federirano · non-IID	925.65	290.86	0.132	4.14×


× vs najbolji = koliko je puta RMSE veći od najboljeg modela (rezidualni LSTM = 1.00×). Najbolji federirani je 2.92× lošiji, non-IID čak 4.14×.

Federirano učenje: rezultati




ALGORITAM	SCENARIJ	RMSE	R ²
FedAvg	IID	657.00	0.561
FedProx	IID	652.06	0.567
FedAvg	non-IID	925.69	0.132
FedProx	non-IID	925.65	0.132

- non-IID: **42 % viši RMSE** od IID; R^2 0.567 $\rightarrow$ 0.132
- FedProx $\approx$ FedAvg; μ jedva pomaže
- Dijagnostika: 1 klijent $\approx$ centralizirani (281)




Neravnomjerna raspodjela po stanicama čini non-IID teškim

Ista metoda daje vrlo različit rezultat o stanici: federirani model nije jednako dobar svugdje.



Stanica 1023: federirani promašuje skokove



Stanica 1037: federirani prati dobro

Greška se koncentrira na velikim i atipičnim stanicama; globalni model je kompromis, što upućuje na potrebu za personalizacijom.

ZAKLJUČAK

- Zadatak je jako sezonski
- Rezidualni LSTM najbolji: R^2 0.947
- Federirano zaostaje za centraliziranim
- non-IID heterogenost je glavno ograničenje
- Točnost: rezidualni LSTM; privatnost: federirano uz dodatne metode

BUDUĆI RAD

- Federirana varijanta rezidualnog učenja
- Personalizacija i klasteriranje sličnih stanica
- Treniranje na više podataka (više gradova i stanica)



Hvala na pažnji

Zvonimir Žunić · Zagreb, 2. srpnja 2026.